Benchmark des modèles Ollama

Choix d'un modèle local pour la mission · 10 novembre 2026

1. Méthode

- **Machine :** Intel Core i5 de 13e génération (série H, 12 cœurs logiques), 16 Go de RAM DDR5, Windows 11, Ollama 0.40.16. Aucune carte graphique utilisée : les modèles tournent sur le processeur.
- **Présélection :** 31 modèles de la bibliothèque Ollama. Un modèle est compatible si sa taille plus 2 Go de marge tient dans la mémoire, moins 4 Go laissés à Windows, soit 9,7 Go maximum sur notre machine.
- **Test :** 6 prompts en français pour les modèles de génération (fait simple, calcul, extraction JSON, résumé, information absente, code Python) et 6 questions de recherche de documents pour les modèles d'embedding. 3 essais par prompt, température 0.
- **Validation :** qualité ≥ 60 %, vitesse ≥ 5 tokens par seconde, JSON valide ≥ 80 %, aucune erreur. Note sur 100 : qualité 50 %, vitesse 20 %, format 15 %, stabilité 15 %.
- **Outil :** tout est automatisé par le script `benchmark_llm.py`. Le script et ce rapport ont été préparés avec l'aide d'un assistant IA (Claude, d'Anthropic) ; les tests ont été exécutés sur notre machine.

2. Résultats mesurés

Modèles de génération (18 essais par modèle)

Mesure	gemma3:1b	deepseek-r1:1.5b
Verdict	**Valide**	**Non valide** (format JSON)
Note sur 100	87	62
Qualité	83 %	83 %
Vitesse	38 tokens par seconde	26 tokens par seconde
Temps par réponse	1,0 s	12,0 s
Temps de chargement	1,6 s	1,9 s
Mémoire utilisée	0,82 Go	1,21 Go
Réponses JSON valides	100 %	0 %
Stabilité (réponses identiques)	67 %	0 %

Modèles d'embedding (3 essais par modèle ; réussite = bon document retrouvé)

Modèle	Verdict	Note	Réussite	Vitesse	Chargement	Mémoire
embeddinggemma	**Valide**	100	6 sur 6	≈ 20 textes/s	1,1 s	0,65 Go
bge-m3	**Valide**	100	6 sur 6	≈ 11,5 textes/s	2,4 s	1,16 Go
nomic-embed-text	**Non valide** (qualité)	50	3 sur 6	≈ 20 textes/s	0,5 s	0,36 Go
mxbai-embed-large	**Non valide** (qualité)	50	3 sur 6	≈ 8,3 textes/s	0,8 s	0,64 Go

- **gemma3:1b** est rapide et respecte le format JSON, mais il se trompe au calcul.
- **deepseek-r1:1.5b** réussit le calcul, mais il ne rend aucun JSON valide et met 12 secondes par réponse.
- **embeddinggemma** et **bge-m3** retrouvent le bon document pour les 6 questions ; les deux autres n'en retrouvent que 3 avec nos questions en français.

3. Autres modèles du catalogue

Le test complet demande 102 Go de téléchargement et un temps d'exécution trop long sur notre machine. Il a été arrêté après 6 modèles.

Statut	Nombre	Modèles
Mesurés	6	gemma3:1b, deepseek-r1:1.5b, embeddinggemma, bge-m3, nomic-embed-text, mxbai-embed-large
Compatibles avec notre machine, non mesurés	21	llama3.2:1b, **qwen3.5:0.8b**, qwen2.5-coder:3b, llama3.2:3b, phi4-mini, qwen3.5:2b, gemma3:4b, qwen3.5:4b, mistral:7b, gemma4:e2b, qwen2.5-coder:7b, llama3.1:8b, deepseek-r1:8b, gemma4:e4b, qwen3.5:9b, mistral-nemo:12b, gemma4:12b, gemma3:12b, deepseek-coder-v2:16b, deepseek-r1:14b, phi4:14b
Écartés : mémoire insuffisante	4	gpt-oss:20b, gemma4:26b, qwen3.6:27b, qwen3-coder:30b

4. Choix du modèle

Modèle retenu : qwen3.5:0.8b. C'est un modèle léger et récent : 1,2 Go pour un maximum de 9,7 Go sur notre machine, avec l'appel d'outils, les images et une fenêtre de contexte de 256 000 tokens d'après sa fiche Ollama. Les modèles de taille comparable que nous avons mesurés dépassent 26 tokens par seconde.

Limite. Ce modèle est compatible avec notre machine, mais il n'a pas été mesuré par le script avant l'arrêt du test. Parmi les modèles mesurés, le seul généraliste validé est gemma3:1b (87 sur 100). Le score de qualité est automatique et le jeu de test est petit : ces résultats sont à compléter par une lecture des réponses.

Annexe. Exécution du script sur notre machine

